

Yazılım Ekosisteminde 'Hype' ve 'Realite' İkilemi: C# Üzerine Bir Doğal Dil İşleme Analizi

The Hype vs. Reality Dilemma in the Software Ecosystem: An NLP Analysis on C#

Sencer Fırtına, Celal Mert Türkay

Özetçe—Bu proje, günümüz yazılım dünyasında içerik platformlarındaki teknolojik trendler (Hype) ile sahadaki geliştiricilerin karşılaştığı teknik sorunlar (Reality) arasındaki ayrımsal boşluğu istatistiksel ve algoritmik olarak ölçmeyi hedeflemektedir. C# ekosistemi temel alınarak, Dev.to platformu üzerinden toplanan makale başlıkları ile Stack Overflow platformundan çekilen gerçek sorun başlıkları üzerinde Zayıf Etiketleme (Weak Supervision) tabanlı bir Doğal Dil İşleme (NLP) analizi gerçekleştirilmiştir. TF-IDF ve Multinomial Naive Bayes algoritmalarının kullanıldığı yapay zeka modeli, yapılandırılmamış ve gürültülü metinler üzerinde %84.12'lik bir sınıflandırma başarısu göstermiştir. Çalışmanın ana katkısı, sadece ayrık sınıflandırma yapmak yerine, Kosinüs Benzerliği (Cosine Similarity) metriği aracılığıyla yeni veya bilinmeyen metinlerin "Hype" ve "Realite" ağırlık merkezlerine (Centroid) olan vektörel ve açısal uzaklıklarını hesaplayabilen sürekli (continuous) bir ölçüm modeli sunmasıdır. Bu sayede bir ifadenin salt bir pazarlama terimi mi yoksa somut bir mühendislik problemi mi olduğu istatistiksel bir oranla kanıtlanabilmiştir.

Anahtar Kelimeler—doğal dil işleme; makine öğrenmesi; zayıf etiketleme; tf-idf; kosinüs benzerliği; c#.

Abstract—This project aims to statistically and algorithmically measure the differential gap between technological trends (Hype) on content platforms and the actual technical problems (Reality) faced by developers in the field. Based on the C# ecosystem, a Natural Language Processing (NLP) analysis utilizing Weak Supervision was conducted on article titles gathered from the Dev.to platform and real issue titles extracted from Stack Overflow. The artificial intelligence model, which employs TF-IDF and Multinomial Naive Bayes algorithms, demonstrated a classification accuracy of 84.12% on unstructured and noisy texts. The main contribution of this study is that, rather than merely performing discrete classification, it offers a continuous measurement model capable of calculating the vectorial and angular distances of new or unknown texts to the "Hype" and "Reality" centroids via the Cosine Similarity metric. Consequently, it has been statistically proven whether a statement is a pure marketing term or a concrete engineering problem.

Keywords—natural language processing; machine learning; weak supervision; tf-idf; cosine similarity; c#.

I. GİRİŞ

Günümüz yazılım mühendisliği ekosistemi, teknolojik ilerlemelerin ve yeni araçların duyurulma hızı sebebiyle eşi görülmemiş bir bilgi bombardımanı altındadır. Blog platformlarında, teknoloji bültenlerinde ve sosyal medyada "Yapay Zeka (AI)", "Temiz Mimari (Clean Architecture)", "Otonom Ajanlar (Autonomous Agents)" veya "Mikroservisler (Microservices)" gibi kavramlar sürekli olarak öne çıkarılmaktadır. Blog içerik üreticileri, okunma oranlarını, platform etkileşimlerini ve görünürlüklerini artırmak amacıyla sıklıkla bu popüler terimlerin cazibesinden yararlanmaktadır. Ancak, bu pazarlama odaklı teknoloji trendlerinin ("Hype") yarattığı yankı odası (echo chamber) ile sahadaki yazılım geliştiricilerinin kurumsal projeleri ayağa kaldırırken veya yaşatırken karşılaştığı gerçek mühendislik sorunları ("Reality") arasında çok ciddi ve göz ardı edilen bir ayrım mevcuttur.

Gerçek saha şartlarında geliştiriciler; popüler framework'lerin soyut vaadlerinden ziyade `NullReferenceException`, çoklu okuma/yazma (concurrency) sorunları, bellek sızıntıları (memory leaks), eski (legacy) sistem entegrasyon zorlukları ve veritabanı performans dar boğazları gibi oldukça somut, acı verici ve teknik problemlerle boğuşmaktadır. Bu ikili evren arasındaki iletişim kopukluğu, özellikle sektöre yeni adım atan geliştiriciler için yanıltıcı bir vizyon çizmektedir. Genç mühendisler, popüler makalelerin yansıttığı tablo yüzünden endüstrinin sadece en yeni paradigmalar etrafında döndüğü yanılgısına düşmekte ve gerçek dünyadaki sorun çözme (troubleshooting) yeteneklerini geliştirmekte eksik kalmaktadır.

Bu projenin temel motivasyonu, yazılım dünyasındaki algı ile gerçeklik arasındaki bu devasa uçurumu sadece anekdotlara veya subjektif gözlemlere dayanarak değil, Doğal Dil İşleme (NLP) ve Makine Öğrenmesi (Machine Learning) tekniklerini kullanarak matematiksel bir çerçevede kanıtlamaktır. Bu çalışma, sadece kural tabanlı bir metin sınıflaması (Binary Classification) yapmanın ötesine geçerek, metinlerin vektörel uzaydaki konumlarını analiz etmeyi hedeflemiştir. Yüksek boyutlu (high-dimensional) Seyrek Matris (Sparse Matrix) uzayında hesaplanan Kosinüs Benzerliği (Cosine

Similarity) aracılığıyla, herhangi bir yazılım argümanına objektif bir "Hype Yüzdesi" ve "Realite Yüzdesi" atanması sağlanmış, böylece teknoloji ekosistemindeki söylemlerin soyutluk derecesi sayısallaştırılmıştır.

II. GEÇMİŞ ÇALIŞMALAR

Yazılım ekosistemindeki geliştirici eğilimleri, metin verileri ve Doğal Dil İşleme metodolojileri üzerine literatürde giderek artan bir ilgi mevcuttur. Bu bölümde, son yıllarda (2024-2026) yayımlanmış, projenin felsefesiyle doğrudan örtüşen beş temel çalışma incelenmiştir.

İlk olarak, Farhour ve arkadaşları (2024) tarafından sunulan çalışmada [1], yazılım mühendisliği alanındaki veri setlerinde sıkça karşılaşılan "etiketlenmiş veri eksikliği" probleminde odaklanılmıştır. Araştırmacılar, kod depolarına entegre edilen sohbet botlarının (chatbots) performansını artırmak amacıyla Zayıf Etiketleme (Weak Supervision) yöntemini kullanmış ve manuel etiketleme maliyetlerinden kaçınarak başarılı bir metin sınıflandırma modeli oluşturmuşlardır. Bu çalışma, projemizdeki kural tabanlı zayıf etiketleme stratejisinin akademik uygulanabilirliğine güçlü bir referans teşkil etmektedir.

İkinci olarak, 2025 tarihli geniş çaplı bir literatür taramasında [2], yazılım mühendisliğinde üretilen metinlerin (kod yorumları, belgeler ve tartışma forumları) sadece teknik değil, aynı zamanda psikodilbilimsel (psycholinguistic) özellikler barındırdığı incelenmiştir. Geliştiricilerin kullandığı kelimelerin, onların iş yükünü, stres seviyelerini ve karşılaştıkları bilişsel engelleri nasıl yansıttığı analiz edilmiş; bu durum metin madenciliğinin yazılımcı psikolojisini anlamadaki önemini vurgulamıştır.

Üçüncü çalışma, geliştiricilerin üretken yapay zeka araçlarına (ChatGPT vb.) karşı tutumlarını ölçen 2024 tarihli bir anket araştırmasıdır [3]. Araştırma sonuçları, sektöre yeni giren yazılımcıların AI araçlarının kapasitesine dair abartılı beklentileri (Hype) ile, kıdemli mühendislerin bu araçları gerçek projelerde konumlandırırken karşılaştığı kısıtlamalar (Reality) arasında belirgin bir tezat olduğunu göstermiştir.

Dördüncü olarak, açık kaynak projelerindeki geliştirici duyarlılığını (sentiment) inceleyen çalışmada [4], kod depolarındaki farklı metin türlerinin duygu durumları karşılaştırılmıştır. Bulgular, hata (bug) çözümü ve sistem çökmesi gibi konuları içeren mesajların (issue reports), genel teknoloji bloglarındaki veya dökümantasyonlardaki metinlere kıyasla istatistiksel olarak çok daha "negatif" ve "teknik olarak yoğun" bir duygu barındırdığını kanıtlamıştır. Bu makale, çalışmamızdaki "Realite" modelinin neden bambaşka bir kelime uzayına (ağırlık merkezine) kaydığının teorik açıklamasını sunmaktadır.

Son olarak, "Stack Overflow Is Not Dead Yet: Crowd Answers Still Matter" başlıklı 2025 tarihli makalede [5],

büyük dil modellerinin (LLM) yükselişine rağmen Stack Overflow gibi kitle kaynaklı (crowdsourced) platformların neden hala kritik olduğu tartışılmıştır. Yapay zekanın sağladığı jenerik cevapların aksine, sahada karşılaşılan benzersiz uç durum (edge-case) hataları ve mühendis feryatlarının ancak insan deneyimiyle çözülebileceği vurgulanmıştır. Bu durum, projemiz için Stack Overflow'un mutlak "Realite" veri kaynağı olarak seçilmesinin doğruluğunu pekiştirmektedir.

III. YÖNTEM

Proje mimarisi; veri toplama (data ingestion), ön işleme (preprocessing), zayıf etiketleme (weak supervision) ve makine öğrenmesi algoritmalarının entegrasyonu (TF-IDF, Naive Bayes ve Cosine Similarity) olmak üzere birbirini izleyen dört ana modülden oluşmaktadır.

A. Kullanılan Veri Seti

Modelin, C# ve .NET ekosistemindeki güncel eğilimleri yansıtabilmesi için iki farklı kaynaktan gerçek zamanlı olarak toplamda yaklaşık 3000 adet yapılandırılmamış başlık verisi çekilmiştir:

- **Hype Verisi (Dev.to):** Pazarlama ve teknoloji trendlerini yakalamak amacıyla, geliştirici blog platformu Dev.to'nun C# etiketi altındaki makaleler hedef alınmıştır. Veri çekimi için Python'un Selenium web otomasyon kütüphanesi kullanılmış ve platformdaki sonsuz kaydırma (infinite scroll) mekanizması aşılarak en güncel ve en çok okunan 500'den fazla makale başlığı kazanılmıştır.
- **Reality Verisi (Stack Overflow):** Sahadaki gerçek sorun spektrumunu elde etmek için requests kütüphanesi aracılığıyla resmi Stack Exchange API kullanılmıştır. Pagination (sayfalama) yöntemiyle, son dönemde C# etiketi ile sorulmuş, geliştiricilerin hata arama ve kodlama sorunlarını içeren 2500'den fazla soru başlığı sisteme dahil edilmiştir.

B. Veri Ön İşleme (Preprocessing) Aşamaları

Farklı API ve web sayfalarından gelen ham metinler, makine öğrenmesi algoritmaları için oldukça yüksek oranda gürültü (noise) barındırmaktaydı. Bu durumun önüne geçmek için uygulanan NLP ön işleme adımları şunlardır:

1. **HTML Dekodlaması:** Stack Overflow API'sinden dönen metinlerde yer alan ' (kesme işareti) veya & (ve işareti) gibi HTML kaçış karakterleri, Python'un yerleşik `html.unescape()` fonksiyonu kullanılarak doğal dil formatına çevrilmiştir. Bu adım, modelin "doesn't" ile "doesn't" kelimelerini ayrı boyutlar (feature) olarak algılayıp TF-IDF matrisini şişirmesini engellemiştir.

2. Noktalama ve Sayı İzolasyonu: Tüm başlıklar küçük harfe (lowercase) çevrildikten sonra, string.punctuation kullanılarak noktalama işaretlerinden arındırılmış ve .isalpha() metodu yardımıyla "2026", "8" gibi sayısal ifadeler analiz dışı bırakılmıştır.

3. Etki Alanına Özgü (Domain-Specific) Stopwords Filtrelemesi: NLP projelerinde sık kullanılan genel İngilizce stopwords listesine ek olarak, Kümeler (Sets) veri yapısının sunduğu kesişim (intersection) özelliği kullanılarak özel bir "çöp" (stopwords) listesi oluşturulmuştur. Hem Hype hem de Realite verisinde çok sık geçen "class", "method", "app", "get", "way" gibi ayırt ediciliği (Information Gain) düşük olan kelimeler tespit edilmiş ve matristen uzaklaştırılmıştır.

C. Uygulanan Algoritmalar ve Frameworkler

Proje geliştirme sürecinde, veri manipülasyonu için pandas ve lineer cebirsel matris işlemleri için numpy kütüphanelerinden yararlanılmıştır.

Zayıf Etiketleme (Weak Supervision): 3000 satırlık verinin manuel olarak etiketlenmesinin pratikte imkansız olması sebebiyle kural tabanlı (rule-based) bir heuristik geliştirilmiştir. Ayrıntılı frekans analizi sonucunda elde edilen Hype kelimeleri (ai, agent, clean, modern, pattern vb.) ve Realite kelimeleri (error, exception, fix, null, crash vb.) doğrudan başlığın içinde aranmıştır. Eşleşme sağlanan veriler 1 (Hype) veya 0 (Realite) olarak etiketlenirken, eşleşmeyen belirsiz veriler (-1) model eğitiminden çıkarılarak net bir sinyal (signal) elde edilmiştir.

Vektörizasyon: Etiketlenmiş veriler, Scikit-Learn (sklearn) kütüphanesindeki TfidfVectorizer kullanılarak Terim Frekansı-Ters Belge Frekansı (TF-IDF) yöntemiyle sayısallaştırılmıştır. Bu dönüşüm

sayesinde metinler, bellek verimliliği sağlamak adına Seyrek Matris (Sparse Matrix) formatında yüksek boyutlu uzaya yerleştirilmiştir.

Sınıflandırma Modeli: Sayısal vektörler kullanılarak Multinomial Naive Bayes algoritması eğitilmiştir. Hype verisinin azlığı ve Realite verisinin fazlalığı arasındaki dengesizliği gidermek adına, veri seti eğitim (%80) ve test (%20) olarak bölünürken stratify=y parametresi kullanılmış, modelin baskın sınıfa doğru yanlılık (bias) göstermesi önlenmiştir.

Merkez (Centroid) Analizi ve Kosinüs Benzerliği: Yalnızca test seti üzerinde 0 veya 1 tahmini yapmakla yetinilmeyip, uzaydaki "Ortalama Hype Vektörü" ile "Ortalama Realite Vektörü" hesaplanmıştır (Matrisin axis=0 üzerinden ortalamasının alınmasıyla). Yeni bir metnin bu merkezlere olan uzaklığı ise, vektörlerin uzunluğundan bağımsız olarak sadece açısal farka odaklanan Kosinüs Benzerliği (Cosine Similarity) formülüyle ölçülmüştür:

$$\cos(\theta) = (A \cdot B) / (||A|| ||B||)$$

IV. SONUÇLAR VE DEĞERLENDİRME

Katı kurallarla filtrelenerek tamamen temizlenen 1162 adet etkili veri üzerinde eğitilen model, daha önce hiç görmediği 233 sınav verisi üzerinden test edilmiştir. Tablo I'de sunulan performans karnesinde görüldüğü üzere, sistem %84.12'lik yüksek bir genel Doğruluk Oranına (Accuracy) ulaşmıştır. Doğal Dil İşleme gibi bağlamın sürekli değiştiği yüksek gürültülü (noisy) bir problem uzayında bu oran, modelin ezberleme (overfitting) yapmadan verideki asıl örüntüyü yakaladığını kanıtlamaktadır.

Modelin tezimizi kanıtlayan asıl ve en güçlü başarısı, Kosinüs Benzerliği tabanlı "Merkez Uzaklık Analizi"nde ortaya çıkmıştır. Tablo II'de, tamamen zıt karakterdeki iki test cümlesinin ağırlık merkezlerine olan yüzdesel çekim kuvvetleri sunulmuştur.

Tablo I. Sınıflandırma Modelinin Başarımları Metrikleri

Sınıf (Etiket)	Precision	Recall	F1-Score	Support
Reality (0)	0.82	0.99	0.90	160
Hype (1)	0.97	0.51	0.67	73
Genel Doğruluk	%84.12 (Test Verisi: 233)			

Sınıf bazlı metriklere bakıldığında, modelin Reality (0) sınıfını bulmadaki Recall (Duyarlılık) oranının muazzam bir şekilde 0.99'a ulaştığı görülmektedir. Bunun teknik nedeni, sahadaki hata feryatlarının (null reference, crash, exception) oldukça tutarlı ve köşeli bir kelime uzayına sahip olmasıdır. Hype (1) sınıfında Recall değerinin nispeten düşük kalmasının sebebi ise, pazarlama dilinin çok daha geniş, dinamik ve esnek (clean, new, modern, pattern vs.) bir kelime dağarcığı kullanmasıdır.